广东工业大学
GUANG DONG UNIVERSITY OF TECHNOLOGY

广东工业大学 2021级自动化学院
本科毕业论文答辩

基于深度学习的光刻热点检测算法研究

答辩人 |　　班级 |　　指导老师 |

日期：2025年5月23日

Contents

目 录

1 研究主要工作

2 多尺度层次图建模方法设计

3 基准模型设计: 图像+度量学习框架

4 改进模型设计: 图族+消息传递框架

5 模型实验 (1) : 性能

6 模型实验 (2) : 消融实验

1 研究主要工作

标题：基于**深度学习**的**光刻热点检测**算法研究

团结 · 勤奋 · 求是 · 创新

“光刻热点”：**集成电路芯片光刻版图**印刷失败的高风险区域，影响芯片良率、制造稳定性

须在设计过程中，预防性**检测**版图中潜在的热点

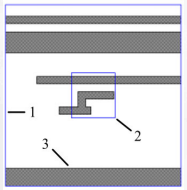

设计版图

问题(制造)

预防(设计)

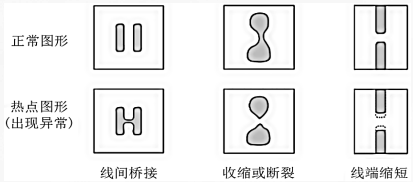

制造问题突显 (热点)

主要工作围绕光刻版图作为深度学习输入特征的**结构建模**、利用**深度学习模型**实现高效识别

① 现有**版图**建模问题：宏观信息表示能力、图形属性细节不足 → 提出 → **多尺度层次图 (graph)**

② 现有**模型**问题：局部特征学习能力不足 → 提出 → **度量学习**模型（基准模型）

③ 现有**模型**问题：宏观特征学习能力、版图中心区域注意力低 → 提出 → **GNN** 模型（改进模型）

④ **性能测试：ICCAD**数据集，改进相比基准，准确率**42.6%**↑ 召回率**89.1%**↑ 误报率**84.3%**↓
优于 **TCAD’2025、GLSVLSI’2024、TODAES’2022** 等**主流模型**
消融实验：核心模块权重对**性能**表现**作用突出**，**有效改善**现有方法针对的不足之处。

2 多尺度层次图(graph)建模方法设计

团结 · 勤奋 · 求是 · 创新

现有**版图**建模：**问题①** 宏观信息表示能力、**问题②** 图形属性细节不足

本研究新提出：**多尺度层次**图建模方法

解决 ①

层次结构设计

- 特点：“**图族**”结构 = **「25 个局部子图」+「1 个全局大图」**
- **子图**：表达局部几何与拓扑细节（水平+垂直+多边形节点）
- **大图**：捕捉区域间上下文依赖与宏观空间组织特性
- 对比论文：Yan et al. ICCAD 2025，单层次 (仅子图) 效率不足 (GNN传播效率,节点数量)

解决 ②

节点/边属性优化

- **节点属性**：除基本几何图形特征外，附加 **DFT 多维分量**
  (例如：相邻结构重叠边的数量频率分布 → DFT)
- **子图边连接**：垂直/水平划分，同一光刻区域对应多边形节点
  (参考：Yu et al. 2017 的完备版图划分方案)
- **大图边连接**：体现子图间光刻区域的**相连关系**，**滤除弱连接**
- 对比论文：Sun et al. DATE 2022，节点与边连接不紧密，属性信息量不充分

子图层构造

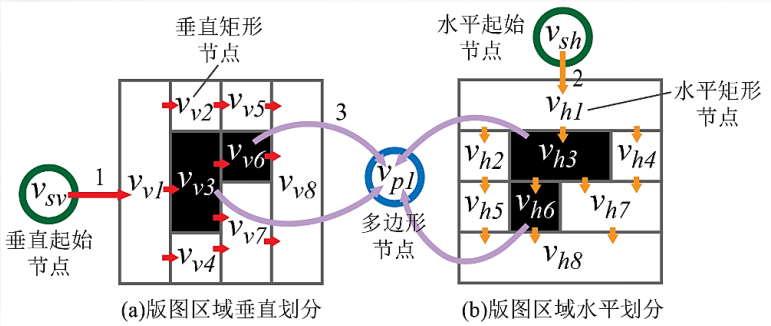

大图层构造

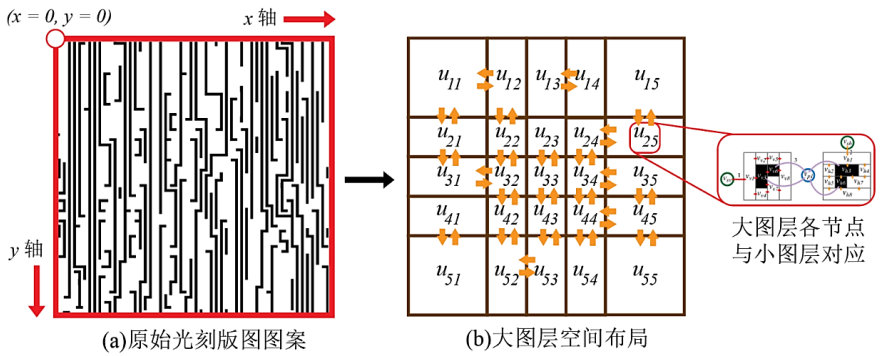

3 基准模型设计：图像+度量学习框架

团结 · 勤奋 · 求是 · 创新

现有**模型**：**问题③** 局部特征学习能力不足

解决 ③

核心模块

Inception 模块

分支卷积 (多核) + 池化 + 拼接
突出邻近图案局部特征

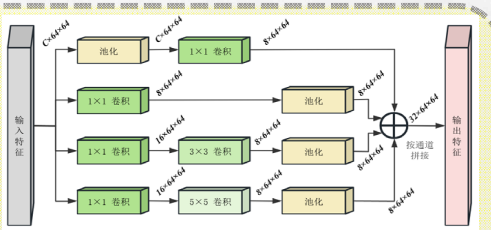

*原文图 3.6

注意力机制 (CWA,SWA)

分别按**通道**、**空间**处理，相乘
突出热点空间响应、语义通道

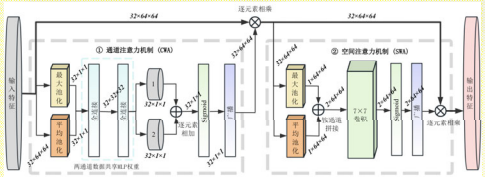

*原文图 3.7

分支训练

两段式训练，先度量学习器，冻结后训练二分类器

度量学习器特殊学习策略：**半难负样本 + 三元组监督**策略

① **三元组监督策略**：
确保距离正样本比负样本小 α

$$\mathcal{L}_{\text{triplet}} = \max\left(\|\mathbf{z}_a - \mathbf{z}_p\|_2^2 - \|\mathbf{z}_a - \mathbf{z}_n\|_2^2 + \alpha, 0\right)$$

② **优先选取**半难 (semi-hard) 负样本：
正负样本间有一定距离，但相距 M 内

$$\|\mathbf{z}_a - \mathbf{z}_p\|_2^2 \le \|\mathbf{z}_a - \mathbf{z}_n\|_2^2 \le \|\mathbf{z}_a - \mathbf{z}_p\|_2^2 + M$$

每组训练样本：
锚点样本、正样本、
负样本

$$(\mathbf{z}_a, \mathbf{z}_p, \mathbf{z}_n)$$

检测模式：光刻版图 → 图像 → **图像二分类问题**

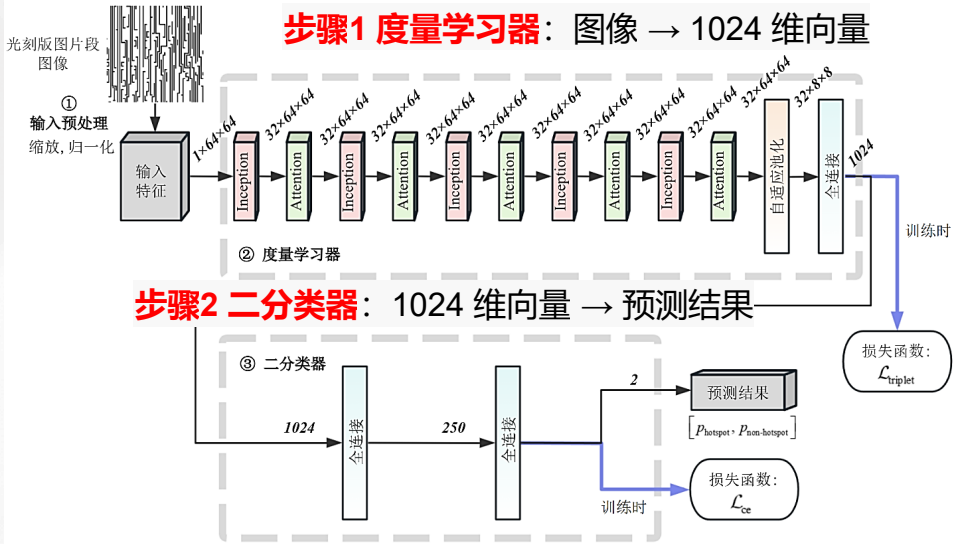

4 改进模型设计：图族+消息传递框架（GNN）

团结 · 勤奋 · 求是 · 创新

现有**模型**：**问题④** 宏观特征学习能力、**问题⑤** 版图中心区域注意力低

解决 ④

步骤1 各图分类：大图、子图（内环、中环、外环）

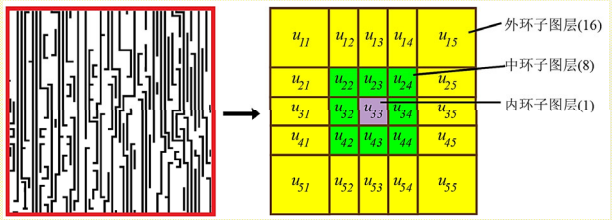

步骤2 四组 GNN 权重推理

三路子图 GNN 分别处理外/中/内环 → **层次结构解耦**

大图 GNN 建模子图间关系，**包含位置与结构相似性**

4 组独立权重支持并行训练，提升模型感知空间

检测模式：光刻版图 → 图族(本研究新建模法) → **图二分类问题**

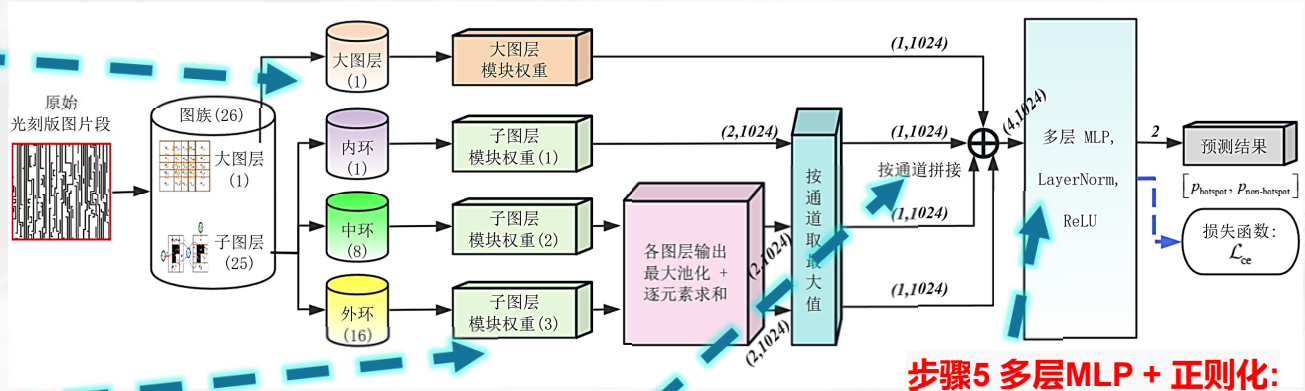

步骤4 特征汇总 $\mathbf{f}_{fused} = \left[\mathbf{f}_{outer} \| \mathbf{f}_{middle} \| \mathbf{f}_{inner} \| \mathbf{f}_{global}\right] \in \mathbb{R}^{4d}$

步骤5 多层MLP + 正则化：

(4, 1024) → 预测结果

解决 ⑤

步骤3 GNN 基本框架

特征处理：加权3跳 + 1跳 消息传递 (MPNN) 模块 ***(backbone)***

$$\mathbf{m}_i^{(k)} = \sum_{j \in \mathcal{N}^{(k)}(i)} \phi_k(a_{ij}) \cdot \mathbf{h}_j^{(l-1)}$$

$$\mathbf{h}_i^{(1)} \to \mathbf{h}_i^{(2)} \to \cdots \to \mathbf{h}_i^{(L)}$$

门控加权：**通道注意力门控**机制，兼顾局部边界特征与中远程结构语义注意力模式在GNN的新引入

$$\mathbf{h}_i^{(l)} = \sigma\left(\alpha^{(1)} \cdot \mathbf{m}_i^{(1)} + \alpha^{(2)} \cdot \mathbf{m}_i^{(2)} + \alpha^{(3)} \cdot \mathbf{m}_i^{(3)}\right)$$

$$\boldsymbol{\alpha}^{(k)} \in [0,1]$$

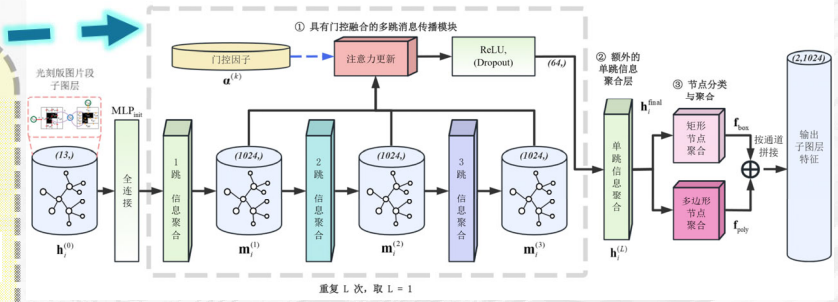

5 模型实验(1)：性能

团结 · 勤奋 · 求是 · 创新

实验设置

项目	内容
实验平台	NVIDIA A100 GPU + Intel Xeon Platinum 8368, 1TB 内存, Ubuntu 20.04
软件环境	Python 3.12，PyTorch 2.5.1，CUDA 12.4
数据集	ICCAD'12、ICCAD'19（含 TNSB 样本）
评估指标*	**准确率**（Accuracy）、**召回率**（Recall）、**误报率**（False Alarm Rate）

*注：指标分别衡量**整体判断能力**、对**热点敏感性**、**误判情况**。

参数量对比

模型	本文CNN模型	本文GNN模型
参数量	2,384,675	28,062,594

GNN模型所利用的多尺度融合结构的建模方法，
需要**高度复杂**的图神经结构进行处理；
但对业界高性能硬件而言，时延仍在可接受水平 (2s)

性能结果

① 不同数据集对比 (纵向)

数据集	模型	准确率	召回率	误报率	推理时间(每64样本)
ICCAD'12	基准模型	96.80%	88.96%	0.18%	0.0196s
	改进模型	96.81%	91.47%	2.27%	1.9640s
ICCAD'19-1 含大量TNSB项（更困难）	基准模型	69.30%	52.83%	7.12%	0.0089s
	改进模型	**98.87%**	**99.91%**	**1.12%**	2.1245s
	对比：	**42.6%↑**	**89.1%↑**	**84.3%↓**	

GNN与图族结构配合下性能提升尤其显著

② 与主流模型对比 (横向)

*数据集基于**更困难的 ICCAD'19-1**

模型	原理	召回率	误报率
本文改进模型	**GNN + 图族结构**	**99.91%**	**1.12%**
TCAD'2025 (Yan et al.)	GNN + 单层次图	91.30%	8.40%
TODAES'2022 (Jiang et al.)	CNN + 贝叶斯优化	76.00%	2.60%
GLSVLSI'2024 (Wang et al.)	CNN + 特征融合学习	62.30%	3.70%
本文基准模型	CNN + 度量学习	52.83%	7.12%

本文改进模型，在召回率和误报率上均**优于近三年主流图神经网络与 CNN 方法**

6 模型实验(2)：消融实验

团结 · 勤奋 · 求是 · 创新

实验方法：移除或简化两个模型的不同结构或模块，评价模型性能影响

本文基准模型

实验项	准确率	召回率	推理时间
原始模型 (baseline)	98.86%	89.97%	0.0081s
移除: 注意力模块	48.78%	**0.53%**	↓
简化: 卷积结构	48.39%	11.74%	↓
简化: 分类器	≈ 98.87%	≈ 89.94%	≈

注意力机制对热点识别起关键作用，分类器结构可简化但**主干必须保留**。

解决问题 局部特征学习能力不足

本文改进模型

实验项	准确率	召回率	误报率	说明
移除: 大图层GNN参数	**75.14%**	≈ 99.9%	**24.86%**	缺失全局上下文建模能力
移除: 内环子图GNN参数	87.50%	**14.72%**	≈	无法精准捕捉热点核心结构
消息传播模块: 降为一跳传播（OH）	88.13%	35.64%	↑	降低了远程依赖感知能力

大图层参数提供空间上下文依赖建模，**缺失将严重影响误报率**

解决问题 宏观特征学习能力不足

内环子图层参数是检测“热点核心”的关键模块，**直接决定召回能力**

解决问题 版图中心区域注意力低

广东工業大學
GUANG DONG UNIVERSITY OF TECHNOLOGY

恳请各位评委老师批评指正！

—— 路漫漫其修远兮，吾将上下而求索